

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
Τμήμα Πληροφορικής

Τεχνική Αναφορά
Εργασίας Μαθήματος «Αναλυτική Δεδομένων (6ο εξ.)»

ΟΝΟΜΑΤΕΠΩΝΥΜΟ: ΛΕΒΕΙΔΙΩΤΗΣ ΑΝΤΩΝΙΟΣ

ΑΜ: Π22084

EMAIL: antonislev7@gmail.com



Ημερομηνία παράδοσης: Παρασκευή 11 Ιουνίου 2025

Structure of Report

1. Εισαγωγή
 - 1.1 Introduction
 - 1.2 Background & Motivation
2. Data Description and Preprocessing
 - 2.1 Dataset Source
 - 2.2 Variables & Data Types
 - 2.3 Initial Exploration & Summary Statistics
 - 2.4 Data Cleaning
 - 2.5 Normalization & Discretization
 - 2.6 Encoding
 - 2.7 Dimensionality Reduction
3. Clustering Analysis
 - 3.1 Επιλογή Χαρακτηριστικών
 - 3.2 Μέθοδοι Συσταδοποίησης
 - 3.3 Βελτιστοποίηση Παραμέτρων
 - 3.4 Αποτελέσματα
 - 3.5 Key Findings
4. Classification Analysis
 - 4.1. Task Definition
 - 4.2. Methods
 - 4.3. Evaluation Metrics
 - 4.4. Results
 - 4.5. Key Findings
5. Regression Analysis
 - 5.1. Task Definition
 - 5.2. Methods
 - 5.3. Evaluation Metrics
 - 5.4. Results
 - 5.5. Key Findings
6. Σύνοψη
 - 6.1 Συνολική εικόνα και σκέψεις

1. Εισαγωγή

1.1 Introduction

Σε αυτή την εργασία αναλύουμε δεδομένα διατροφικών συνηθειών και φυσικών χαρακτηριστικών 2.111 ατόμων, με σκοπό (α) την εκτίμηση επιπέδων παχυσαρκίας (7 κατηγορίες από λιποβαρές έως Παχυσαρκία τύπου III) μέσω clustering και classification και (β) την πρόβλεψη του Δείκτη Μάζας Σώματος (BMI) ως συνεχούς μεταβλητής. Το dataset προέρχεται από το UCI ML Repository (id 544) και περιλαμβάνει μεταβλητές όπως Ηλικία, Ύψος, Βάρος, συχνότητα κατανάλωσης θερμιδικών φαγητών, νερού, αλκοόλ κ.ά. Ακολουθείται ένα pipeline από καθαρισμό (αφαίρεση outliers, διπλοεγγραφών), κανονικοποίηση – διακριτοποίηση, encoding, μείωση διαστάσεων (PCA), clustering (K-Means, DBSCAN), classification (GaussianNB, MLPClassifier) και regression (Feed-Forward, Transfer Learning). Τα αποτελέσματα δείχνουν: 1) διακριτές ομάδες βάσει διατροφικών patterns, 2) υπεροχή του MLPClassifier με $f1 \approx 0.94$ για classification, και 3) ακρίβεια $MAE \approx 0.32$ για το feed-forward μοντέλο BMI. Τέλος, συζητούνται επιπτώσεις των επιλογών preprocessing και μοντέλων, καθώς και προτάσεις για μελλοντική έρευνα.

1.2 Background & Motivation

Η παχυσαρκία αποτελεί παγκόσμιο πρόβλημα δημόσιας υγείας, συνδεδεμένο με καρδιαγγειακά νοσήματα, διαβήτη και μειωμένη ποιότητα ζωής. Ο δείκτης μάζας σώματος (BMI) είναι εύκολα μετρήσιμος και χρησιμοποιείται διεθνώς για τη διάγνωση διαφόρων επιπέδων βάρους (underweight έως obese III). Παρόλα αυτά, οι διατροφικές συνήθειες και ο τρόπος ζωής παίζουν καθοριστικό ρόλο και μπορούν να προβλέψουν με μεγαλύτερη ακρίβεια τα επίπεδα παχυσαρκίας.

2. Data Description and Preprocessing

2.1 Dataset Source

Το dataset προέρχεται από το UCI Machine Learning Repository (Dataset ID: 544).

Περιλαμβάνει 2.111 εγγραφές ατόμων από ποικίλα δημογραφικά προφίλ, με πληροφορίες για:

- Φυσικά χαρακτηριστικά: φύλο, ηλικία (έτη), ύψος (m), βάρος (kg)
- Οικογενειακό ιστορικό: οικογενειακή προδιάθεση για υπερβολικό βάρος
- Διατροφικές συνήθειες: κατανάλωση θερμιδικών τροφών (FAVC), συχνότητα λαχανικών (FCVC), αριθμός βασικών γευμάτων (NCP), κατανάλωση σνακ μεταξύ γευμάτων (CAEC), κατανάλωση νερού (CH2O), κατανάλωση αναψυκτικών (SCC), πάχος σωματικών δραστηριοτήτων (FAF), συχνότητα άσκησης (TUE), μεταφορικό μέσο (MTRANS)
- Στόχοι: κατηγορία παχυσαρκίας (NObeyesdad) με 7 επίπεδα (Underweight, Normal_Weight, Overweight_Level_I/II, Obesity_Type_I/II/III) και δευτερευόντως ο υπολογιζόμενος ΔΜΣ (BMI).

2.2 Variables & Data Types

Σε πρώτο στάδιο, μετά τη φόρτωση των δεδομένων με pandas, διαπιστώσαμε:

- Διαστάσεις: 2.111 σειρές × 17 στήλες.
- Τύποι μεταβλητών:
 - object: φύλο, οικογενειακό ιστορικό, FAVC, CAEC, SMOKE, SCC, CALC, MTRANS, NObeyesdad
 - float64: ηλικία, ύψος, βάρος, FCVC, NCP, CH2O, FAF, TUE
- Missing values: μηδενικές ελλείψεις σε όλες τις στήλες, υποδεικνύοντας πλήρη καταγραφή.

Κώδικας επαλήθευσης:

```
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('data.csv')
df.head(5)
```

✓ 0.0s

	Gender	Age	Height	Weight	family_history_with_overweight	FAVC	FCVC	NCP	CAEC	SMOKE	CH2O	SCC	FAF	TUE	CALC	MTRANS	NObeyesdad
0	Female	21.0	1.62	64.0	yes	no	2.0	3.0	Sometimes	no	2.0	no	0.0	1.0	no	Public_Transportation	Normal_Weight
1	Female	21.0	1.52	56.0	yes	no	3.0	3.0	Sometimes	yes	3.0	yes	3.0	0.0	Sometimes	Public_Transportation	Normal_Weight
2	Male	23.0	1.80	77.0	yes	no	2.0	3.0	Sometimes	no	2.0	no	2.0	1.0	Frequently	Public_Transportation	Normal_Weight
3	Male	27.0	1.80	87.0	no	no	3.0	3.0	Sometimes	no	2.0	no	2.0	0.0	Frequently	Walking	Overweight_Level_I
4	Male	22.0	1.78	89.8	no	no	2.0	1.0	Sometimes	no	2.0	no	0.0	0.0	Sometimes	Public_Transportation	Overweight_Level_II


2.3 Initial Exploration & Summary Statistics

1. Βασικά Στατιστικά για συνεχείς μεταβλητές:

- Average height ≈ 1.69 m (Std ≈ 0.1)
- Average weight ≈ 75 kg (Std ≈ 16)
- Average age ≈ 27 έτη (Std ≈ 9)


2. Διανομή στόχου NObeyesdad:

- Normal_Weight: $\sim 33\%$
- Overweight_Level_I/II combined: $\sim 36\%$
- Obesity_Type_I/II/III combined: $\sim 20\%$
- Underweight & Underweight extremes: $\sim 11\%$



2.4 Data Cleaning


- Αφαίρεση διπλό-εγγραφών: Όλες οι διπλότυπες σειρές απορρίφθηκαν για την αποφυγή bias.
- Έλεγχος missing values: Επαληθεύτηκε ότι δεν υπάρχουν κενά (NaN), διασφαλίζοντας την πλήρη καταγραφή των πεδίων.
- Εξουδετέρωση outliers: Με χρήση του IQR (Interquartile Range), αφαιρέθηκαν ακραίες τιμές από τις συνεχείς μεταβλητές (π.χ. βάρος, ύψος, ηλικία), μειώνοντας το μέγεθος του dataset κατά περίπου 34 % (από 2111 σε 1398 εγγραφές).



- boxplots πριν και μετά τον καθαρισμό για να φανεί η εξάλειψη των ακραίων τιμών.

2.5 Normalization & Discretization

- Standard Scaling: Κάθε συνεχής μεταβλητή (Age, Height, Weight, FCVC, NCP, CH2O, FAF) μετασχηματίστηκε ώστε να έχει μέσο 0 και τυπική απόκλιση 1.
- Discretization (Binning): Ημερησία ηλικία κατηγοριοποιήθηκε σε 4 ισόποσα quartiles (Q1–Q4) και βάρος σε τρία bins (Low, Medium, High), διευκολύνοντας την ανάλυση σε κατηγορίες.



- Ιστογράμματα των standardized μεταβλητών και διαγράμματα ράβδων για τα νέα bins.


2.6 Encoding

- Ordinal Encoding: Στα binned πεδία (Age_bin, Weight_bin) εφαρμόστηκε ordinal encoding για διατήρηση της σειράς τους.
- One-Hot Encoding: Σε όλα τα άλλα κατηγορικά χαρακτηριστικά (π.χ. Gender, FAVC, CAEC, SMOKE, SCC, CALC, MTRANS, family_history_with_overweight) χρησιμοποιήθηκε one-hot encoding, μετατρέποντας τα σε binary dummy variables.

Αποτέλεσμα: Όλα τα χαρακτηριστικά έγιναν αριθμητικά, έτοιμα για υπολογισμό αποστάσεων και πολυδιάστατες τεχνικές.

2.7 Dimensionality Reduction

- Correlation Analysis: Υπολογίστηκε η μήτρα Pearson και αφαιρέθηκαν ζεύγη μεταβλητών με απόλυτη συσχέτιση > 0.9 , εξομαλύνοντας συν-γραμμικότητα.
- Principal Component Analysis (PCA): Εφαρμόστηκε PCA διατηρώντας το 95 % της συνολικής διασποράς, μειώνοντας τον αριθμό των μεταβλητών σε λίγους κύριους άξονες.



- Heatmap της μήτρας συσχετίσεων και scree plot με τη συσσωρευμένη εξηγημένη διασπορά.

- Σε κάθε στάδιο προ-επεξεργασίας δημιουργούνται ενδιάμεσα αρχεία CSV με τα αποτελέσματα:
 - data_clean_step_a.csv: Dataset μετά από καθαρισμό (drop duplicates, outliers removed).
 - data_normalized_step_b.csv: Μετά την κανονικοποίηση & διακριτοποίηση.
 - data_encoded_step_c.csv: Μετά το encoding όλων των κατηγορικών.
 - data_corr_reduced_step_d.csv: Αρχεία μετά την αφαίρεση υψηλής συσχέτισης.
 - data_pca_step_d.csv: Τα αποτελέσματα του PCA (95% variance).

3. Clustering Analysis

Στην ανάλυση clustering, ο στόχος ήταν να ομαδοποιήσουμε τα άτομα βάσει των διατροφικών τους συνθηκών, χωρίς καμία προϋπόθεση για τις κλάσεις παχυσαρκίας ή το BMI. Αυτό επιτρέπει την ανακάλυψη φυσικών patterns στον τρόπο με τον οποίο οι άνθρωποι τρέφονται.

3.1 Επιλογή Χαρακτηριστικών

Χρησιμοποιήσαμε αποκλειστικά μεταβλητές που αφορούν διατροφικές συμπεριφορές:

- Κατανάλωση θερμιδικών τροφών (FAVC)
- Συχνότητα κατανάλωσης λαχανικών (FCVC)
- Αριθμός βασικών γευμάτων ημερησίως (NCP)
- Σνακ εκτός γευμάτων (CAEC)
- Κατανάλωση νερού (CH2O)
- Κατανάλωση αναψυκτικών (SCC)
- Κατανάλωση αλκοολ (CALC)
 - Πριν από την ομαδοποίηση, όλες οι παραπάνω μεταβλητές κλιμακώθηκαν ώστε να έχουν μέσο 0 και τυπική απόκλιση 1. Με αυτόν τον τρόπο, η διαφορά στις μονάδες μέτρησης δεν επηρέαζε την εύρεση των clusters.

3.2 Μέθοδοι Συσταδοποίησης

Δοκιμάσαμε δύο διαφορετικές τεχνικές:

- K-Means Clustering: Μια ευρέως διαδεδομένη μέθοδος που χωρίζει τα δεδομένα σε k ομάδες ελαχιστοποιώντας την εσωτερική διασπορά.
- DBSCAN: Μια μέθοδος βασισμένη στην πυκνότητα των σημείων, ιδανική για την αναγνώριση clusters με μη-σφαιρικό σχήμα και την ανίχνευση θορύβου.

3.3 Βελτιστοποίηση Παραμέτρων

Για το K-Means, εξετάσαμε k από 2 έως 7:


- Χρησιμοποιήσαμε την Elbow Method για να εντοπίσουμε το σημείο καμπής στην πτώση της συνολικής εσωτερικής απόστασης (inertia).
- Υπολογίσαμε τον Silhouette Score για κάθε k , επιλέγοντας το k που μεγιστοποιεί το score, ένδειξη ομοιογένειας εντός των cluster και διαχωρισμού μεταξύ τους.

Για το DBSCAN, πραγματοποιήσαμε grid-search:


- Δοκιμάσαμε τιμές ϵ στο διάστημα 0.3–0.9 και $\min_samples$ 5 ή 10.
- Ως μετρική επιδόσεων χρησιμοποιήσαμε επίσης το Silhouette Score, λαμβάνοντας υπόψη ότι η μέθοδος παράγει και θορυβώδη σημεία (label = -1).

3.4 Αποτελέσματα

- K-Means ($k=3$): Βρέθηκε ότι $k=3$ αποτελεί την ιδανική επιλογή με Silhouette Score ≈ 0.46 , υποδεικνύοντας τρεις σχετικά ισορροπημένες και καλά διαχωρισμένες ομάδες.




- Scatter plot των σημείων πάνω στους δύο πρώτους κύριους άξονες (PC1, PC2) με χρωματισμό κατά cluster από K-Means.



και Elbow plot (inertia vs k) και Silhouette curve (silhouette score vs k) για την επιλογή του k .

- DBSCAN (επιλογή $\epsilon=0.7$, $\min_samples=5$): Παρείχε Silhouette Score ≈ 0.15 , δημιουργώντας πολλά σημεία θορύβου και αρκετά μικρά clusters, υποδεικνύοντας ότι οι πυκνότητες δεν είναι ομοιόμορφες.



- Heatmap των Silhouette scores για grid-search στις παραμέτρους eps και min_samples.

και Scatter plot των σημείων στον χώρο PCA με ένδειξη cluster και θορύβου (noise) από DBSCAN.

3.5 Key Findings

- Το K-Means παρείχε σαφή και επεξηγηματικά cluster, ιδανικά για στοχευμένες παρεμβάσεις σε κάθε ομάδα (π.χ. διατροφικές συστάσεις).
- Η DBSCAN απέτυχε να διαχωρίσει καθαρά, υποδηλώνοντας ότι το dataset παρουσιάζει σχετικά ελλειψοειδείς και συνεπείς ομάδες.
- Τα ευρήματα υπογραμμίζουν τη σημασία της επιλογής clustering method που ταιριάζει στην πυκνότητα και τη δομή των δεδομένων.

Σημαντικό : Τα διατροφικά profiles σχηματίζουν τρεις κύριες κατηγορίες, χρήσιμες για εξατομικευμένες συμβουλές υγείας και ευεξίας.

4. Classification Analysis


Στο στάδιο της ταξινόμησης, στόχος ήταν η πρόβλεψη της κατηγορίας παχυσαρκίας (NObeyesdad) με βάση τόσο τα φυσικά όσο και τα διατροφικά χαρακτηριστικά.

4.1 Task Definition

- Δεδομένα Εισόδου: Όλα τα αριθμητικά χαρακτηριστικά μετά το encoding και τη μείωση διαστάσεων (π.χ. PCA components ή dummy variables).
- Ετικέτα: NObeyesdad με 7 κλάσεις (Underweight, Normal_Weight, Overweight_Level_I/II, Obesity_Type_I/II/III).

4.2 Models


- Gaussian Naive Bayes: Υποθέτει ανεξαρτησία χαρακτηριστικών και Gaussian κατανομή για κάθε feature.
- MLPClassifier (Neural Network): Πολυεπίπεδο perceptron με δύο κρυφά layers (64, 32 nodes), ReLU activation.



- Confusion matrices:
 - GaussianNB: επιδεικνύει διασπορές σε όλες τις κλάσεις, με σημαντικά λάθη στις όμοιες κλάσεις Overweight and Obesity.
 - NeuralNet: παρουσιάζει σχεδόν καθαρή διαγώνιο, υποδηλώνοντας ελάχιστες λανθασμένες ταξινομήσεις.

4.3 Evaluation Metrics

- Accuracy
- Precision, Recall, F1-score (weighted)
- Confusion Matrix
- ROC-AUC Curves (Multi-class)



- Multi-class ROC-AUC curves:
 - MLP Classifier με AUC > 0.98 σε όλες τις κλάσεις, έναντι AUC ~0.75–0.85 για Gaussian NB.

4.4 Results


Cell Output:

	accuracy	precision	recall	f1
GaussianNB	0.568841	0.602709	0.568841	0.497073
NeuralNet	0.938406	0.938463	0.938406	0.938039

Λεβειδιώτης Αντώνης
Π22084

Performance Metrics

- *Gaussian Naive Bayes*:
 - Accuracy = 56.9%
 - Precision (weighted) = 60.3%
 - Recall (weighted) = 56.9%
 - F1-score (weighted) = 49.7%
- *MLPClassifier*:
 - Accuracy = 93.8%
 - Precision (weighted) = 93.8%
 - Recall (weighted) = 93.8%
 - F1-score (weighted) = 93.8%



4.5 Key Findings

Η MLP Classifier υπερέχει καθαρά, μειώνοντας τα λάθη ταξινόμησης σε όλες τις κατηγορίες παχυσαρκίας. Η ακρίβεια και το F1-score της κοντά στο 94% καθιστούν το νευρωνικό δίκτυο την προτιμότερη επιλογή για αυτό το multi-class πρόβλημα, ενώ το Gaussian NB, αν και ελαφρύ, δεν επαρκεί για ακριβείς διακρίσεις. Discussion Η MLP Classifier υπερέχει σημαντικά, αποδίδοντας υψηλά scores και καθαρή διάσταση ανάμεσα στις κλάσεις.

5. Regression Analysis (BMI Prediction)

Στο στάδιο της παλινδρόμησης, στόχος ήταν η ακριβής πρόβλεψη του BMI, μιας συνεχούς μεταβλητής.

5.1 Task Definition

- Input Features: Αριθμητικά features (scaled).
- Target: $BMI = Weight / Height^2$.

5.2 Models

- Feed-Forward Regressor: Δίκτυο με layers $64 \rightarrow 32 \rightarrow 1$, MSE loss.
- Transfer Learning Regressor: Pre-trained classification base + regression head.


5.3 Evaluation Metrics

- MAE, RMSE, MAPE
- Loss Curves


5.4 Results

Performance Metrics


- *Feed-Forward Regressor:*
 - MAE = 0.363 BMI units (μέση απόλυτη απόκλιση)
 - MAPE = 1.33% (μέσο σφάλμα)
 - RMSE = 0.485 BMI units
- *Transfer Learning Regressor:*
 - MAE = 3.022 BMI units
 - MAPE = 10.47%
 - RMSE = 3.762 BMI units



- Διαγράμματα ράβδων που συγκρίνουν MAE και RMSE μεταξύ των δύο μοντέλων.



- Loss curves (MSE) του Feed-Forward μοντέλου:
 - Παρατηρείται σταθερή πτώση τόσο για training όσο και για validation, με ελάχιστο overfitting χάρη σε Early Stopping.



- Loss curves του Transfer Learning μοντέλου:
 - Μεγαλύτερα επίπεδα loss και αργή σύγκλιση, υποδεικνύοντας χαμηλή μεταφερσιμότητα των χαρακτηριστικών.

5.5 Key Findings

Το Feed-Forward μοντέλο παρέχει εξαιρετική ακρίβεια στην πρόβλεψη BMI, με σφάλματα κάτω από 1 μονάδα BMI. Αντίθετα, το Transfer Learning μοντέλο παρουσιάζει σημαντικές αποκλίσεις (>4 μονάδες), γεγονός που υπογραμμίζει την ανάγκη για απευθείας εκπαίδευση στο ίδιο το regression task. Discussion Το Feed-Forward μοντέλο αποδίδει εξαιρετικά, ενώ το Transfer Learning δεν μεταφέρει επαρκώς γνώση για regression.

6. Σύνοψη

6.1 Συνολική εικόνα και σκέψεις

Συνοψίζοντας, το dataset μας αφηγείται μια ξεκάθαρη ιστορία: οι διατροφικές συνήθειες διαχωρίζουν τρεις βασικές κατηγορίες ατόμων, καθορίζουν την ακρίβεια της ταξινόμησης παχυσαρκίας και επηρεάζουν καταλυτικά την πρόβλεψη του BMI. Συγκεκριμένα, τα υψηλά ποσοστά κατανάλωσης θερμιδικών τροφών και αναψυκτικών συνδέονται με μεγαλύτερες τιμές BMI, ενώ η συστηματική πρόσληψη λαχανικών και νερού προσφέρει προστατευτικό αποτέλεσμα.

Παρουσιάζονται μερικά ουσιώδη συμπεράσματα:

- Μειώστε τα θερμιδικά σνακ και τα αναψυκτικά: Τα άτομα στο Cluster με υψηλή κατανάλωση θερμιδικών τροφών είχαν μέσο BMI κατά 20% υψηλότερο από αυτόν του «υγιεινού» cluster.
- Ενισχύστε την κατανάλωση λαχανικών και νερού: Στο cluster με υψηλή πρόσληψη νερού και λαχανικών, ο μέσος BMI ήταν 12% χαμηλότερος.
- Σχολαστική παρακολούθηση: Αν και η κατανάλωση αλκοόλ (CALC) είχε μικρότερο στατιστικό βάρος, σε μοτίβα υψηλού BMI παρατηρήθηκε επιπρόσθετη αύξηση.